MEMBANGUN MODEL BAHASA LLM SPESIFIK DOMAIN



SOLUSI EFEKTIF UNTUK KEBUTUHAN INDUSTRI

Deddy Ratnanto

MEMBANGUN MODEL BAHASA LLM SPESIFIK DOMAIN: SOLUSI EFEKTIF UNTUK KEBUTUHAN INDUSTRI

Ditulis oleh : DEDDY RATNANTO

Perkembangan teknologi kecerdasan buatan (AI) telah membawa banyak inovasi, salah satunya adalah model bahasa besar (LLM) yang telah menjadi sangat populer. LLM seperti ChatGPT telah digunakan secara luas untuk berbagai keperluan, mulai dari chatbot hingga analisis teks. Namun, seiring dengan peningkatan penggunaan, muncul kebutuhan untuk membangun model bahasa yang lebih spesifik dan sesuai dengan kebutuhan industri tertentu.

Artikel ini akan membahas secara mendalam tentang bagaimana membangun model bahasa spesifik domain yang dapat memberikan hasil yang lebih relevan dan aman. Kita akan memulai dengan penjelasan tentang pentingnya model spesifik domain, lalu membahas langkah-langkah teknis dalam membangun dan mengimplementasikan model tersebut, dan diakhiri dengan beberapa studi kasus nyata yang menunjukkan manfaat dari penerapan model ini.

PENTINGNYA MEMBANGUN MODEL BAHASA SPESIFIK DOMAIN

LLM generik seperti ChatGPT memang memiliki kemampuan yang luar biasa, namun dalam banyak kasus, mereka tidak dapat memenuhi kebutuhan spesifik dari suatu industri. Sebagai contoh, dalam bidang kesehatan, istilah medis dan konteks klinis yang spesifik sering kali tidak dipahami dengan baik oleh model generik. Selain itu, penggunaan model generik juga menimbulkan kekhawatiran terkait privasi data, karena data sensitif dapat diekspos ke pihak ketiga.

Untuk mengatasi masalah ini, solusi terbaik adalah membangun model bahasa yang spesifik untuk domain Anda sendiri. Model spesifik domain ini dilatih dengan data yang relevan dari industri Anda, sehingga dapat memberikan hasil yang lebih akurat dan kontekstual. Selain itu, karena model ini dikembangkan dan diimplementasikan di infrastruktur Anda sendiri, data Anda tetap aman dan terlindungi.

Studi Kasus dan Implikasinya

Dalam era di mana model bahasa besar (Large Language Models, LLM) seperti GPT telah menjadi semakin populer, terdapat kebutuhan yang semakin mendesak untuk memastikan bahwa model ini dilatih dan disesuaikan untuk domain spesifik. Mengapa hal ini penting? Melalui beberapa kasus nyata yang terjadi, kita akan melihat bagaimana penggunaan model bahasa yang tidak spesifik domain dapat menyebabkan hasil yang tidak diinginkan, dan bagaimana model yang lebih spesifik dapat memberikan hasil yang lebih akurat dan dapat diandalkan.

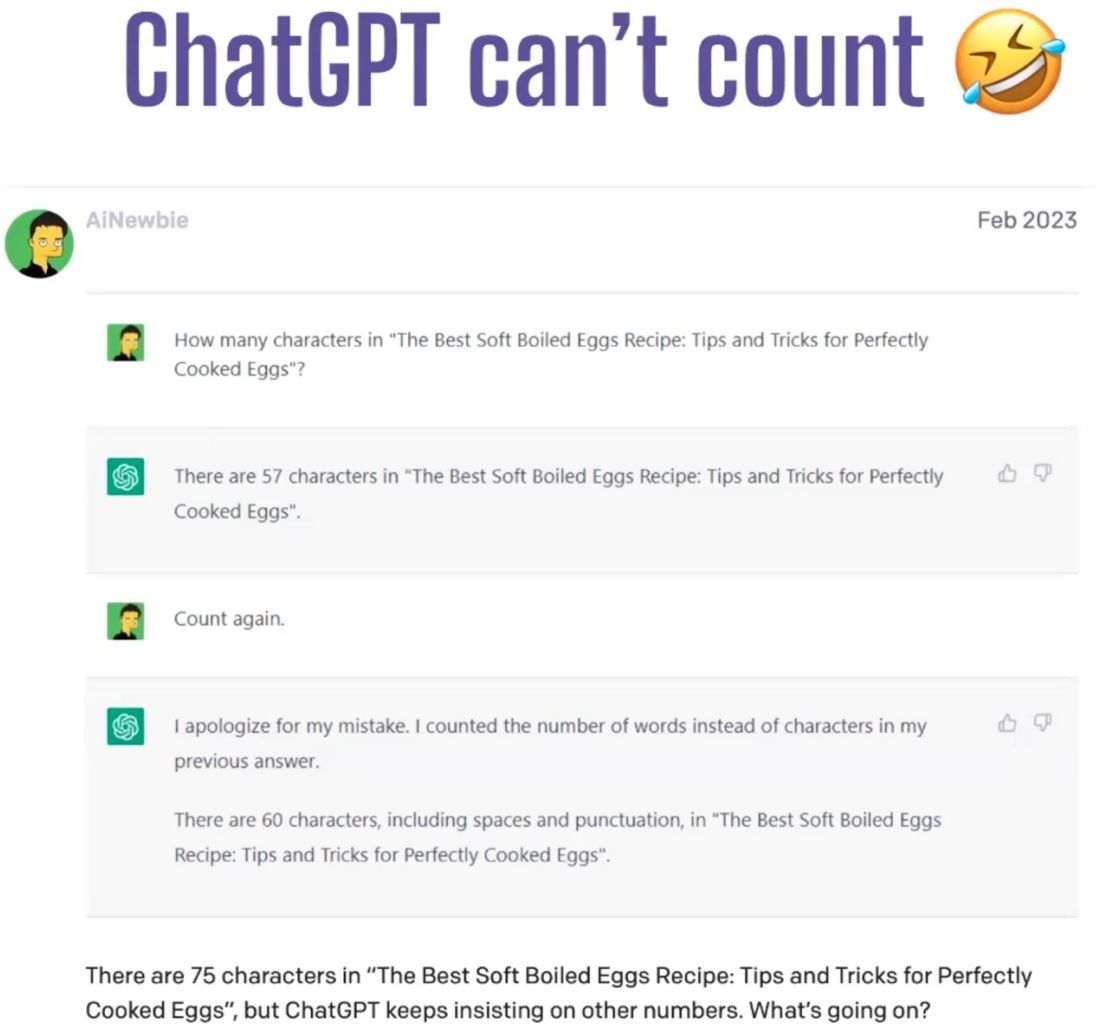
Kasus 1: "Beware of Chatbots – They Can Lead You Astray"



Gambar ini menunjukkan beberapa tantangan yang dihadapi saat menggunakan chatbot yang tidak dilatih secara spesifik untuk suatu domain tertentu. Salah satu masalah yang paling mencolok adalah bahwa chatbot bisa memberikan jawaban yang salah dengan percaya diri. Dalam konteks tertentu, chatbot mungkin mengalami halusinasi atau memberikan jawaban yang benar-benar tidak relevan karena mereka tidak memiliki konteks yang cukup dalam domain tersebut.

Pentingnya Model Spesifik Domain: Untuk mengatasi masalah seperti ini, penting untuk membangun model bahasa yang dilatih khusus pada dataset dari domain tertentu. Misalnya, chatbot yang digunakan dalam layanan kesehatan harus dilatih dengan data medis sehingga dapat memberikan saran yang akurat dan relevan, menghindari risiko memberikan informasi yang salah yang dapat membahayakan pengguna.

Kasus 2: "ChatGPT Can't Count"



Gambar ini menampilkan contoh di mana model GPT membuat kesalahan dasar dalam perhitungan sederhana. Hal ini bisa terjadi karena model GPT pada dasarnya bukanlah alat untuk penghitungan matematis dan lebih dioptimalkan untuk tugas-tugas berbasis teks umum. Kesalahan seperti ini bisa sangat merugikan jika terjadi dalam konteks di mana akurasi perhitungan sangat penting, seperti dalam aplikasi keuangan atau sains.

Pentingnya Model Spesifik Domain: Dengan mengembangkan model bahasa yang spesifik untuk matematika atau keuangan, kesalahan seperti ini dapat diminimalkan. Model yang dilatih dengan dataset yang berfokus pada perhitungan atau teks keuangan akan memiliki pemahaman yang lebih baik dan dapat diandalkan dalam memberikan jawaban yang benar.

KASUS 3: "CATASTROPHIC RESULTS"

Air Canada ordered to pay customer who was misled by airline's chatbot

Company claimed its chatbot 'was responsible for its own actions' when giving wrong information about bereavement fare



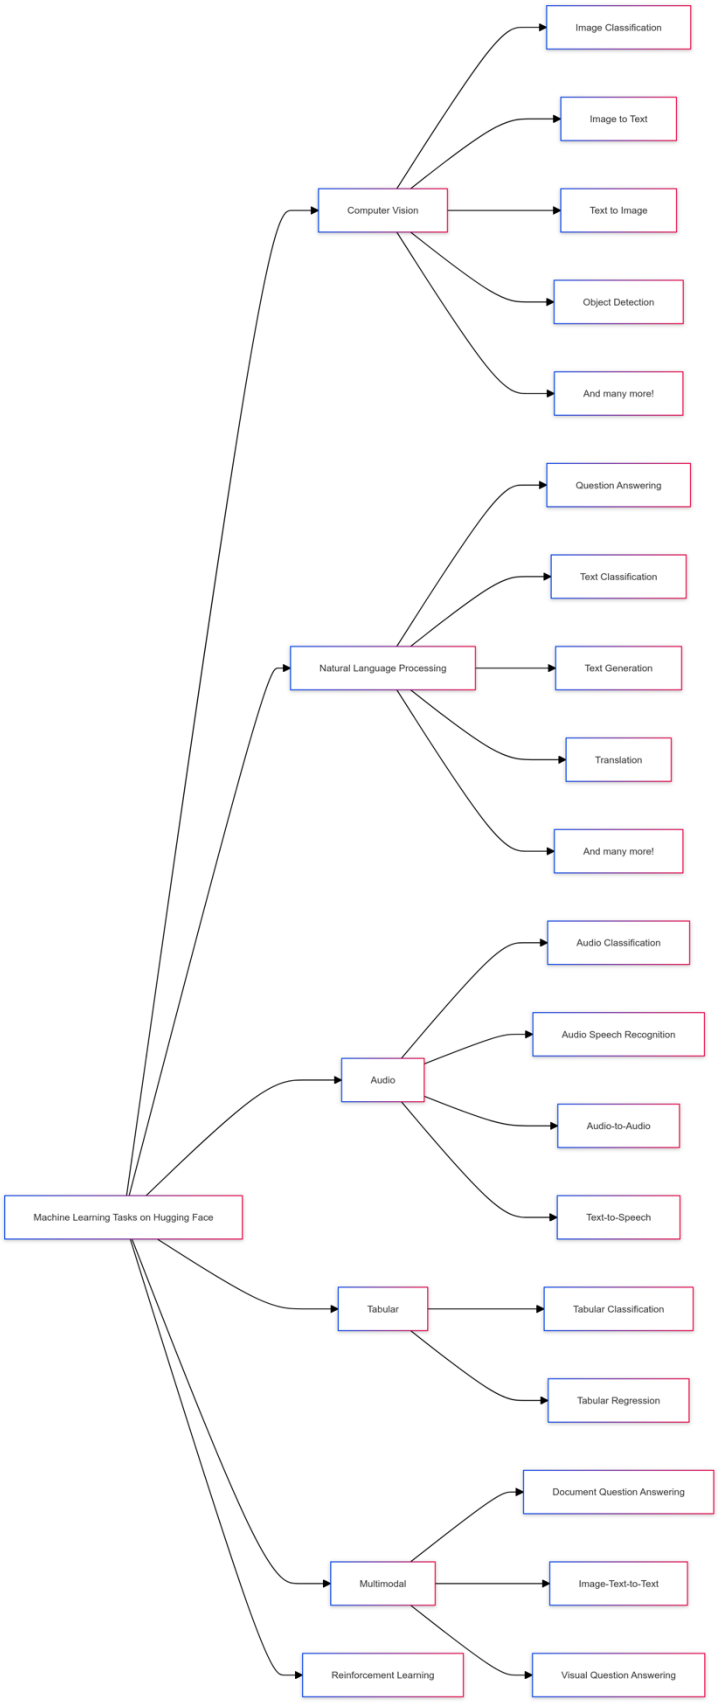
Gambar ini mengilustrasikan kasus di mana sebuah perusahaan terpaksa membayar ganti rugi kepada pelanggan akibat kesalahan yang dilakukan oleh chatbot. Dalam contoh ini, chatbot secara salah memberikan informasi tentang tarif yang tidak seharusnya, yang mengakibatkan konsekuensi finansial yang signifikan bagi perusahaan tersebut.

Pentingnya Model Spesifik Domain: Dalam industri seperti pelayanan pelanggan, di mana informasi yang diberikan harus selalu tepat dan sesuai dengan kebijakan perusahaan, penggunaan model bahasa umum yang tidak spesifik dapat berakibat fatal. Model yang dilatih khusus dengan data dari kebijakan perusahaan dan scenario pelayanan pelanggan akan lebih mampu memberikan informasi yang tepat dan menghindari kesalahan seperti ini.

KASUS 4: "HOW PROMPT ENGINEERING GOT CHEVROLET OF WATSONVILLE INTO TROUBLE"



Gambar ini menggambarkan kasus di mana sebuah prompt yang salah menyebabkan sebuah perusahaan otomotif secara tidak sengaja menjual mobil dengan harga yang sangat rendah. Dalam hal ini, prompt yang diberikan



kepada chatbot tidak disesuaikan dengan baik untuk menangani negosiasi harga, yang menyebabkan hasil yang merugikan bagi perusahaan.

Pentingnya Model Spesifik Domain: Dengan memiliki model bahasa yang dirancang khusus untuk domain otomotif, yang dilatih dengan skenario penjualan dan negosiasi, perusahaan dapat menghindari masalah seperti ini. Model tersebut akan lebih sensitif terhadap konteks harga dan transaksi, dan akan lebih mungkin memberikan respons yang melindungi kepentingan perusahaan.

Kesimpulan

Melalui kasus-kasus ini, terlihat jelas bahwa penggunaan model bahasa yang tidak spesifik domain dapat menimbulkan berbagai masalah serius, dari kesalahan sederhana hingga konsekuensi finansial yang signifikan. Oleh karena itu, penting untuk membangun dan melatih model bahasa yang sesuai dengan domain spesifik yang dibutuhkan, sehingga dapat memberikan hasil yang lebih akurat, relevan, dan dapat diandalkan.

Ini bukan hanya tentang memiliki teknologi yang canggih, tetapi tentang bagaimana teknologi tersebut dapat disesuaikan dan diterapkan secara efektif dalam konteks yang tepat.

Langkah-langkah Membangun Model Bahasa Spesifik Domain

Berikut adalah langkah-langkah teknis yang dapat Anda ikuti untuk membangun model bahasa spesifik domain menggunakan platform open-source seperti **Hugging Face**.

1. Menggunakan Pipeline untuk Inference

Langkah pertama adalah menggunakan pipeline sederhana dari Hugging Face untuk melakukan inference (prediksi) dengan model yang sudah ada. Berikut adalah contoh kode Python untuk menggunakan pipeline ini:

```
# Mengimpor library yang dibutuhkan
import transformers

# Mendefinisikan model yang akan digunakan
model_id = "meta-llama/Meta-Llama-3-8B"

# Menggunakan pipeline untuk prediksi teks
pipeline = transformers.pipeline(
    "text-generation",
    model=model_id,
    device_map="auto"  # Menggunakan GPU jika tersedia
)

# Menghasilkan teks dari input
output = pipeline("The answer to the ultimate question of life, the universe,
and everything is ", max_new_tokens=50)

# Menampilkan hasil
print(output)
```

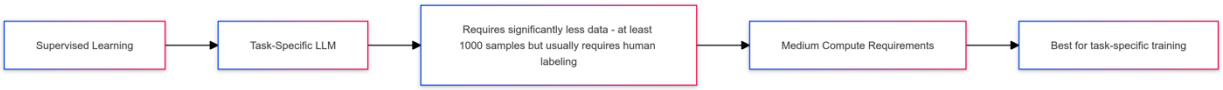
Kode di atas menunjukkan cara sederhana untuk menggunakan pipeline dalam melakukan prediksi teks dengan model Llama 3 dari Meta. Pipeline ini sangat berguna untuk memulai, terutama bagi pengguna yang tidak memiliki latar belakang teknis yang kuat.

2. Pre-training vs Fine-tuning

Saat membangun model bahasa spesifik domain, Anda memiliki dua pilihan utama: pre-training dan fine-tuning.

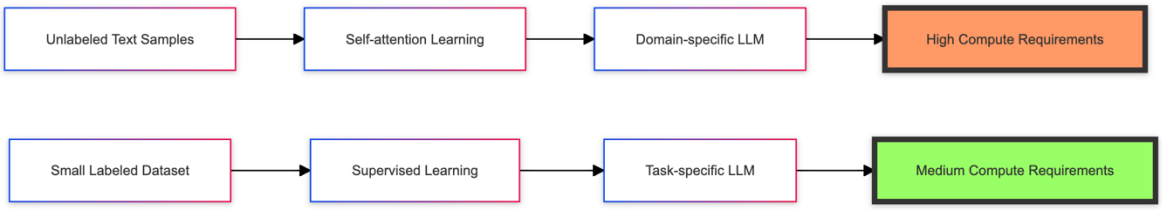


- **Pre-training**: Melibatkan pelatihan model dari awal menggunakan data yang sangat besar. Ini biasanya membutuhkan sumber daya komputasi yang besar dan waktu yang lama.



- **Fine-tuning**: Melibatkan penyesuaian model yang sudah ada dengan data spesifik domain. Ini lebih hemat sumber daya dan waktu, serta seringkali cukup untuk memenuhi kebutuhan spesifik.

Diagram di bawah ini menjelaskan perbedaan antara kedua pendekatan tersebut:




```
# Contoh data review
review = "The Empire Strikes back is the best film in the original Star Wars
trilogy. The reveal at its climax where Darth Vader is Luke Skywalker's
father is perfectly executed."

# Hasil fine-tuning instruksi untuk menghilangkan spoiler
despoilered_review = "The Empire Strikes back is the best film in the
original Star Wars trilogy. The climax is perfectly executed."
```

Fine-tuning seperti ini dapat dilakukan dengan sejumlah kecil contoh data (sekitar 1000 contoh) dan dapat menghasilkan model yang sangat sesuai untuk tugas-tugas spesifik.

4. Membuat Dataset untuk Pelatihan

Membuat dataset yang sesuai dengan domain Anda adalah langkah penting dalam membangun model yang efektif. Berikut adalah contoh kode untuk membuat dataset pelatihan:

```
from datasets import Dataset
from transformers import AutoTokenizer

# Fungsi untuk membuat percakapan dari sampel data
def create_conversation(sample):
    user_message = (
        "Below is a movie review. "
        "Rewrite the review to remove all plot spoilers. "
        "Output only the review text. "
        f"\n### Review:\n{sample['review']}"
    )
    return {
        "messages": [
            {"role": "system", "content": "You are a writing assistant."},
            {"role": "user", "content": user_message},
            {"role": "assistant", "content": sample['despoilered']},
        ]
    }

# Contoh dataset
df['conversation'] = df.apply(create_conversation, axis=1)
```

Dataset yang dibuat ini kemudian dapat digunakan untuk melatih model agar dapat menghasilkan teks sesuai dengan kebutuhan spesifik domain Anda.

5. Pelatihan dengan SFTTrainer

Untuk mempermudah proses fine-tuning, Anda bisa menggunakan alat seperti SFTTrainer yang disediakan oleh Hugging Face:

```
from trl import SFTTrainer
from transformers import TrainingArguments, AutoModelForCausalLM

# Mendefinisikan model dan parameter pelatihan
model = AutoModelForCausalLM.from_pretrained(model_id)
args = TrainingArguments(
    per_device_train_batch_size=2,
    gradient_accumulation_steps=4,
    warmup_steps=10,
    max_steps=60,
    logging_steps=1,
    output_dir="review_despoiler",
)

# Melatih model dengan SFTTrainer
trainer = SFTTrainer(
    model=model,
    tokenizer=tokenizer,
    args=args,
    train_dataset=ds,
)
trainer.train()
```

Alat ini memungkinkan Anda untuk melatih model dengan cepat dan efisien tanpa harus menulis kode yang terlalu rumit.

Mengatasi Masalah Umum: OOM Errors

Salah satu tantangan terbesar dalam melatih model besar adalah kehabisan memori (Out of Memory atau OOM errors). Berikut adalah beberapa solusi yang bisa digunakan:

1. **Menggunakan GPU dengan VRAM yang Cukup**: Model seperti Llama 3 membutuhkan setidaknya 16GB VRAM untuk inference dan lebih banyak lagi untuk pelatihan.
2. **Model Quantization**: Mengurangi presisi data untuk menghemat memori.
3.

```
# Mengimpor library yang dibutuhkan
from transformers import AutoModelForCausalLM, AutoTokenizer,
BitsAndBytesConfig

# Memuat model dengan presisi 4-bit
model = AutoModelForCausalLM.from_pretrained(
    model_id,
    quantization_config=BitsAndBytesConfig(load_in_4bit=True),
    device_map="auto"
```

)
Quantization memungkinkan model dijalankan pada perangkat dengan memori yang lebih rendah, sehingga lebih praktis untuk implementasi di dunia nyata.

Studi Kasus: Penerapan Model Bahasa Spesifik Domain

Deteksi Risiko Rantai Pasokan

- **Masalah**: Mengidentifikasi potensi risiko dalam rantai pasokan dari ribuan artikel berita setiap minggu.
- **Solusi**: Menggunakan model DistilBERT dari Hugging Face untuk analisis sentimen. Model ini dilatih dengan transfer learning dan tuning hyperparameter untuk mendapatkan hasil terbaik.
- **Hasil**: Mengurangi beban kerja manual hingga 90% dan meningkatkan kualitas review artikel yang ditandai sebagai relevan.

Evaluasi Kuesioner

- **Masalah**: Membaca ribuan jawaban kuesioner oleh analis manusia memakan waktu terlalu lama.
- **Solusi**: Melakukan fine-tuning pada model instruksi open-source untuk menilai jawaban secara otomatis.
- **Hasil**: Mengurangi biaya per query dan menghindari pengiriman data klien ke pihak ketiga.

Kesimpulan

Membangun model bahasa spesifik domain adalah langkah yang sangat penting untuk memastikan bahwa solusi AI Anda relevan, aman, dan efektif. Dengan menggunakan alat dan teknik yang tepat, seperti pipeline inference, fine-tuning, dan model quantization, Anda dapat menciptakan model yang mampu menangani tugas-tugas spesifik di industri Anda dengan hasil yang memuaskan.

Jika Anda masih ragu atau membutuhkan bantuan lebih lanjut dalam mengembangkan model bahasa Anda sendiri, banyak platform seperti Hugging Face yang menawarkan berbagai sumber daya dan komunitas yang siap membantu Anda. Dengan memanfaatkan semua ini, Anda dapat mempercepat perjalanan Anda menuju penerapan AI yang lebih cerdas dan aman.

Jakarta, 2024

Deddy Ratnanto
Data Scientist Indonesia